

한국어 특화 CLIP 모델 기반의 멀티모달 이미지 검색 시스템 설계 및 구현

송창석 김정우 조윤기 문형빈 이하은 낭종호
서강대학교 컴퓨터공학과

thdckdtjr7@sogang.ac.kr kjwgod0818@sogang.ac.kr choyoonki@sogang.ac.kr
hbmun@sogang.ac.kr hgray@sogang.ac.kr jhnang@sogang.ac.kr

Design and Implementation of a Multi-modal Image Search System based on Korean-specific CLIP Model

Changseok Song Jeongwoo Kim Yoonki Cho Hyeongbin Mun Haeun Lee JongHo Nang
Department of Computer Science and Engineering, Sogang University

요약

온라인 플랫폼에서 이미지 콘텐츠가 폭발적으로 증가함에 따라 텍스트 쿼리 기반의 정확한 이미지 검색 수요가 높아지고 있으나, 기존 키워드 기반 검색은 이미지의 의미론적 내용을 반영하지 못하고 영어 중심 멀티모달 모델은 한국어 쿼리 처리 시 번역 오버헤드와 품질 저하를 초래한다는 한계가 있다. 본 논문에서는 한국어 특화 CLIP 기반의 멀티모달 이미지 검색 시스템을 제안한다. 카테고리별 프롬프트 매핑과 규칙 기반 품질 검증을 결합한 자동화 파이프라인으로 102만 장 규모의 고품질 이미지-한국어 캡션 데이터셋을 구축하고, 이를 기반으로 한국어 CLIP을 파인튜닝하였다. 또한 사전 계산된 특징 벡터를 GPU 메모리에 상주시켜 디스크 I/O 없이 코사인 유사도 기반 Top-K 검색을 수행한다. 분석 결과, 제안 시스템은 약 100만 장 규모의 실제 산업용 데이터셋에서 평균 7.8ms의 검색 속도를 달성하여 실시간 번역이 필요한 AlignCLIP(FT, 평균 75.8ms) 대비 약 10배 빠른 응답을 제공한다. 또한 카테고리별 프롬프트 매핑을 통해 한국어 쿼리 내 카테고리 키워드를 인식하는 카테고리 인식 검색이 가능함을 확인하였다.

1. 서론

온라인 이미지 콘텐츠의 폭발적 증가로 정밀한 텍스트 검색 수요가 높으나, 기존 메타데이터 기반 검색은 이미지의 본래의 시각적·의미론적 내용을 직접 반영하지 못한다. 특히 디자인 플랫폼 등 대규모 산업용 데이터베이스는 카테고리 내 시각적 편차가 커 사용자의 세밀한 의도를 반영하기 어려우며, 수백만 건에 대한 빠르고 정확한 검색이 필수적이다. 이러한 한계를 보완하기 위해 CLIP[1]과 같은 멀티모달 모델이 활용되고 있으나, 영어 중심으로 학습된 모델을 한국어 검색에 적용할 경우 실시간 번역 지연 및 오차로 인해 검색 품질이 크게 저하된다. 산업용 한국어 CLIP을 위한 대규모 캡션 데이터의 수작업 구축은 비현실적이며, 자동 캡셔닝 및 번역을 결합한 대안 역시 노이즈 통제와 카테고리 특성의 학습 반영이 전제되어야 한다. 따라서 본 논문에서는 한국어 쿼리를 직접 처리하면서 대규모 데이터베이스에서 실시간 검색이 가능하고, 학습 데이터를 자동으로 구축하는 한국어 특화 CLIP 기반 멀티모달 이미지 검색 시스템을 제안한다. 이를 위해 BLIP[2] 캡셔닝과 카테고리별 프롬프트 매핑, LLM 기반 iris-7b[3] 번역, 규칙 기반 품질 검증을 결합한 자동화 파이프라인으로 102만 장 규모의 고품질 이미지-한국어 캡션 데이터셋을 구축하고, 한국어 CLIP[4]을 파인튜닝하여 카테고리 키워드를 인식하는 한국어 검색 모델을 확보하였다. 또한 사전

계산된 특징 벡터를 GPU 메모리에 상주시켜 디스크 I/O 없는 실시간 Top-K 검색 파이프라인을 구현하였다. 약 100만 장 규모의 산업용 데이터셋에서 평균 7.8ms의 검색 속도를 달성하여 AlignCLIP[5] 기반 영어 파인튜닝 모델(75.8ms) 대비 약 10배 빠른 응답을 제공하며, 한국어 쿼리 내 카테고리 키워드를 인식하는 카테고리 인식 검색이 가능함을 확인하였다.


2. 관련 연구

2.1 멀티모달 이미지-텍스트 표현 학습

CLIP[1]은 대조 학습으로 이미지와 텍스트를 공유 임베딩 공간에 정렬해 zero-shot 검색을 가능하게 한다. AlignCLIP[5]은 인코더 파라미터 공유와 intra-modality separation으로 modality gap을 줄여 cross-modal 정렬을 개선한다. 한편 BLIP[2]은 이미지 캡션 생성으로 레이블 없는 데이터에 텍스트 어노테이션 구축한다.

2.2 한국어 이미지 검색

한국어 CLIP[4]은 지식증류[6] 기반으로 한국어 임베딩 공간을 확보하였으나, 일반 도메인 학습에 머물러 산업용 데이터셋 적용에는 도메인 어휘 일반화 성능이 제한적이다. 특히 한국어 특화 쿼리 처리와 대규모 데이터베이스 실시간 검색을 동시에 만족하는 통합 연구는 미흡하다.



<그림 1> 제안 시스템 파이프라인 (Django REST API + PyTorch GPU 기반)

3. 시스템 설계 및 구현

제안 시스템의 전체 파이프라인은 <그림 1>과 같으며, 사용자 요청 처리는 Django REST API로, 검색 추론은 PyTorch 기반 GPU 모듈로 구현하였다.

3.1 데이터셋 구축

데이터셋 구축 단계의 핵심 목표는 검색 품질을 좌우하는 고품질 이미지-한국어 캡션 데이터셋을 자동으로 구축하는 것이다. 이를 위해 카테고리별 프롬프트 매핑을 통한 의미론적 캡션 생성, iris-7b[3] 기반 한국어 번역, 규칙 기반 품질 검증의 3단계 파이프라인을 설계하였다. 먼저 데이터베이스의 이미지를 BLIP[2] 캡셔닝 모델에 입력하되, 카테고리별로 "a photograph of" (photo), "an illustration of" (illust) 등 카테고리 의미가 반영된 prefix를 사용하여 어휘적 분포를 카테고리 특성에 맞게 유도하였다. 이는 동일 카테고리 이미지 간 임베딩 일관성을 높이는 동시에, 학습된 모델이 한국어 쿼리에 포함된 카테고리 키워드("사진", "템플릿" 등)를 검색 결과에 반영할 수 있도록 한다. 생성된 영어 캡션은 iris-7b[3]를 통해 한국어로 번역되며, 이미지-한국어 캡션 쌍을 JSON 형식으로 저장한다. 자동 생성된 캡션은 번역 오류나 캡셔닝 실패로 인해 학습에 부적합한 노이즈를 포함할 수 있으므로, 전체 산업용 데이터 102만 8,521장에 대해 반복 토큰, 비정상 특수문자, 한글 비율 임계값 등을 기준으로 한 규칙 기반

품질 검증을 적용하였다. 그 결과 번역 불량 293장과 캡션 생성 불량 5장을 제거하여 최종 102만 8,223쌍(photo 345,362장, illust 304,631장, template 181,228장, editimage 176,199장, icon 20,803장)의 이미지-한국어 캡션 학습 데이터셋을 구축하였으며, <그림 2>는 카테고리별 예시를 보여준다.

3.2 모델 파인튜닝


한국어 쿼리 검색의 정확도를 높이기 위해 지식 종류 기반으로 텍스트 인코더를 한국어 임베딩 공간에 정렬시킨 한국어 CLIP[4]을 사전 학습 모델로 채택하였다. 해당 모델은 한국어 대응력은 우수하나 산업용 도메인의 특화 어휘 및 시각적 세부 특성을 반영하는 데 한계가 있다. 이를 보완하고자 3.1절에서 구축한 데이터셋을 활용해 이미지 인코더와 텍스트 인코더를 모두 학습하는 이미지-캡션 대조 학습 방식으로 파인튜닝을 진행하였다(<그림 1> 참조). 학습된 모델(이하 Ours)로 데이터베이스의 이미지 및 캡션 특징 벡터를 추출하고 L2 정규화하여 카테고리 정보와 함께 H5 형식으로 저장한다.

3.3 이미지 검색

온라인 검색 단계는 100만 장 규모 데이터의 실시간 처리를 위해 GPU 인메모리(In-memory) 구조로 설계하였다. 시스템 시작 시 사전 계산된 이미지-캡션 특징 벡터 (1,028,223개 × 2(이미지+캡션) × 768차원 × FP16(2 Bytes) ≈ 3.0GB)를 PyTorch 텐서로 GPU에 일괄 적재해 디스크 I/O 병목을 제거하였다. 사용자가 (1) 이미지 검색 또는 (2) 캡션 검색 방식을 선택한 후 쿼리를 입력하면, 파인튜닝된 모델의 텍스트 인코더로 쿼리 벡터를 추출한다. PyTorch의 행렬-벡터 곱(torch.mv) 연산으로 데이터베이스 전체와의 코사인 유사도를 일괄 계산해 상위 k개 이미지를 반환한다. 또한 카테고리 필터링을 보조적으로 지원한다.



<그림 2> 카테고리별 이미지 예시



<그림 3> 검색 품질 정성 비교 : (a) 의미 보존, (b) 카테고리 인식

4. 시스템 분석

4.1 분석 환경

시스템 분석은 RTX 3090에서 영어 기반 AlignCLIP(FT)을 비교 모델로 하여 쿼리당 10회 반복 측정된 평균 Warm Latency를 기준으로 검색 속도·품질을 분석하였다.

4.2 수행 시간 측정을 통한 시스템 효율성 분석

각 모델별 측정 시간은 <표 1>과 같다. 추론 시간은 텍스트 쿼리의 특징 정보 변환 시간, 검색 시간은 약 1,020,000장 기준에 대한 검색 시간이다. 제안 시스템은 <그림 1(a)>와 같이 번역 과정이 생략되어 평균 7.8ms의 지연 시간을 달성했다. 이는 실시간 번역을 거치는 <그림 1(b)> AlignCLIP Pipeline 대비 약 10배 빠른 속도로, 대규모 데이터셋에서의 우수한 검색 효율을 보인다.

<표 1> 모델별 단계별 평균 검색 지연 시간 비교 (ms)

모델	번역	추론	검색	전체
AlignCLIP(FT)	69.0	4.9	1.9	75.8
Ours	—	5.9	1.9	7.8

4.3 검색 품질 분석

제안 시스템의 품질을 이미지 검색 방식을 기준으로 의미 보존과 카테고리 인식 측면에서 정성 평가하였다. "강아지와 함께 누워있는 사람" 등 복합 수식 쿼리에서 제안 모델은 피사체 간 관계 및 구조적 맥락을 정확히 반영한 반면, AlignCLIP(FT)은 번역 과정에서 의미가 분절되어 단어 단위 속성만 강조된 무관 이미지를 반환하였다(<그림 3(a)>). 이는 한국어 직접 임베딩이 문장 내 문맥 정보를 유지하는 데 더 유리함을 입증한다. 카테고리 인식 효과는 카테고리 키워드를 포함한 쿼리로 평가하였다. "바다 수평선 너머로 지는 태양 일러스트" 쿼리에서 제안 모델(Ours)은 illust 카테고리의 일몰 일러스트를 정확히 반환한 반면, AlignCLIP(FT)은 번역 과정에서 "지는 태양"의 의미가 왜곡되고 "일러스트" 키워드가 누락되어 카테고리 의도를 반영하지 못하였다(<그림 3(b)>). 이는 한국어 직접 임베딩이 번역 과정의 키워드 손실 없이 카테고리 의미를 그

대로 보존하여, 자연어 쿼리만으로 세밀한 도메인 제어 가능성 입증한다.

5. 결론 및 향후 연구

본 논문은 고품질 한국어 데이터셋과 파인튜닝을 통해 실시간 대규모 검색 시스템을 제안하였다. 향후에는 부정 표현을 포함한 복합 쿼리 인식 성능을 고도화하여 검색의 정교함을 더욱 높일 예정이다.

사사문구

본 연구는 2026년 과학기술정보통신부 및 정보통신기획평가원의 AI중심대학사업 지원을 받아 수행되었음(2026-0-00036)

참고문헌

- [1] Radford, Alec, et al, "Learning Transferable Visual Models From Natural Language Supervision," *Proceedings of the International Conference on Machine Learning*, pp.8748-8763, 2021.
- [2] Li, Junnan, et al, "BLIP: Bootstrapping language-image pre-training for unified vision-language understanding and generation," *International Conference on Machine Learning*, PMLR, 2022.
- [3] Kim, Chansung, "iris-7b: Korean-English Translation Model," Hugging Face, 2024. <https://huggingface.co/davidkim205/iris-7b>
- [4] Bingsu, "clip-vit-large-patch14-ko," Hugging Face, 2022. <https://huggingface.co/Bingsu/clip-vit-large-patch14-ko>
- [5] Eslami, Sedigheh, and Gerard de Melo, "Mitigate the Gap: Improving Cross-Modal Alignment in CLIP," *The Thirteenth International Conference on Learning Representations*, 2025.
- [6] Reimers, Nils and Iryna Gurevych, "Making Monolingual Sentence Embeddings Multilingual using Knowledge Distillation," *Proceedings of the Conference on Empirical Methods in Natural Language Processing*, pp.4512-4525, 2020.